

Hybrid RAG — сервис поиска для Rumi (@rumicoderbot)

Гибридный поиск по документации Imagine Communications (435 документов).

Rumi использует этот сервис через HTTP (порт 11436) для ответов на вопросы.

Структура

~/projects/pdf-rag/

Архитектура (сентябрь 2026)

Gnoll (человек)

Компоненты

Компонент | Назначение | Статус

|---|---|---|

pdf-rag search server | FastAPI на порту 11436 (systemd `pdf-rag-search.service`). Persistent: ChromaDB+BM25+FlashRank | Работает

hybrid_search.py | Библиотека поиска, дёргается search_server.py | Внутри сервера

ingestion_hybrid.py | Индексация: распаковка архивов → дедупликация → извлечение текста → чанки → эмбединги → ChromaDB + BM25 | Готов

Ollama | Порт 11434, эмбединги nomic-embed-text (только для этого) | Работает

Что НЕ используется

- llama.cpp** (порт 11435) — модель Qwen3-Hermes8B. Rumi не использует локальные LLM.

Поиск (для Rumi)

Через HTTP-сервер — без cold start, ~4 секунды на запрос:

curl -s "http://localhost:11436/search?q=что+такое+Versio"

Формат ответа — PlainText с разделителями `=== source (score=...) ===`.

Индексация (добавление новых документов)

1. Положить файлы (.pdf, .docx, .pptx) в `~/projects/pdf-rag/data/pdfs/`

Векто

└─ d

└─ no

Rumi

(deep

2. Заг

Проверка индекса

количество чанков в ChromaDB

```
.venv/bin/python -c "import chromadb; c=chromadb.PersistentClient('data/chroma'); print(c.get_collection('documents').count())"
```

проверка BM25 индекса

```
.venv/bin/python -c "import pickle; d=pickle.load(open('data/bm25/bm25_index.pkl','rb')); print(f'BM25: {len(d[0])} чанков')"
```

Технические детали

Чанкование

- Размер: 768 слов

Поиск

1. Векторный: ChromaDB, `n\_results=30`

• Ov

2. BM

Эмбединги

- Модель: nomic-embed-text

• Пр

Сервер (systemd)

- Юнит: `pdf-rag-search.service` (user)

• По

Что внутри документов

Документация Imagine Communications (бывшая Harris Broadcast):

• AD

Команды для отладки

переиндексация (если добавили файлы)

```
.venv/bin/python src/ingestion_hybrid.py
```

проверка сервера

```
curl http://localhost:11436/health
```

поиск через HTTP

```
curl -s "http://localhost:11436/search?q=Versio+installation"
```